

Arquitectura de Datos para el análisis de nacimientos en Argentina (2005-2022)

Ministerio de Salud de la Nación



1. Introducción

El análisis de datos en el ámbito de la salud pública permite comprender fenómenos demográficos, identificar tendencias sanitarias y apoyar la toma de decisiones basadas en evidencia.

En Argentina, el Ministerio de Salud difunde diferentes conjuntos de datos abiertos que permiten analizar indicadores clave relacionados con la población y el sistema sanitario.

En este proyecto se desarrolla una **arquitectura de datos analítica** basada en un modelo de **Data Warehouse**, con el objetivo de analizar la evolución de los nacimientos registrados en la República Argentina entre los años **2005 y 2022**.

El proyecto abarca todo el proceso de análisis de datos:

- exploración inicial del dataset
- identificación del grano de análisis
- diseño del modelo dimensional
- proceso ETL mediante Python
- implementación del Data Warehouse
- análisis mediante consultas SQL
- visualización mediante herramientas de Business Intelligence

Este enfoque permite transformar datos crudos en **información analítica útil para la toma de decisiones**.

Objetivo del proyecto

El objetivo de este proyecto es diseñar una arquitectura de datos analítica que permita analizar la evolución de nacimientos en Argentina entre 2005 y 2022, utilizando técnicas de modelado dimensional, procesos ETL y herramientas de Business Intelligence.

2. Contexto institucional

El Ministerio de Salud de la Nación Argentina pone a disposición de la ciudadanía distintos conjuntos de datos a través de su **Portal de Datos Abiertos**, con el objetivo de promover la transparencia y facilitar el análisis de información pública.

Estos datasets permiten estudiar diferentes indicadores sanitarios como:

- natalidad
- mortalidad
- cobertura sanitaria
- indicadores epidemiológicos

El acceso a datos abiertos facilita el desarrollo de proyectos de análisis que pueden aportar valor tanto a la gestión pública como a la investigación académica.

En este contexto, el presente proyecto utiliza datos públicos sobre nacimientos registrados en el país.

3. Dataset seleccionado

El dataset utilizado se denomina:

“Nacidos vivos registrados en la República Argentina (2005-2022)”

Fuente: Portal de Datos Abiertos del Ministerio de Salud de la Nación.

Este conjunto de datos contiene información agregada sobre nacimientos registrados en Argentina según diferentes variables demográficas y sanitarias.

El dataset contiene:

- **546.963 registros**
- **12 variables**

Las variables principales incluyen:

Variable	Descripción
anio	Año del registro
jurisdiccion_residencia	Provincia de residencia
edad_madre_grupo	Grupo etario
instruccion_madre	Nivel educativo
tipo_de_parto	Tipo de parto
semana_gestacion	Intervalo de semanas
intervalo_peso	Peso al nacer
sexo	Sexo del recién nacido
nacimientos_cantidad	Cantidad de nacimientos

Cada registro representa la **cantidad de nacimientos para una combinación específica de estas variables**.

Este tipo de dataset permite analizar tendencias demográficas y sanitarias a lo largo del tiempo, facilitando la identificación de patrones y variaciones en la natalidad según diferentes características de la población.

4. Exploración inicial de datos

Antes de diseñar el modelo analítico, se realizó una **exploración inicial del dataset** utilizando Python y la librería **pandas**.

El objetivo de esta etapa fue comprender la estructura del dataset y detectar posibles problemas de calidad de datos.

El archivo CSV fue cargado en Python mediante el siguiente código:

```
# librerías
import pandas as pd

# ruta del archivo csv
path = r"C:\Users\User\Desktop\Linea Cero\DATA
ANALYTICS\data\proyecto_dw_salud\raw\nacidos-vivos-registrados-en-la-republi
ca-argentina-entre-los-años-2005-2022.csv"

# lectura
df = pd.read_csv(path, encoding="latin-1", low_memory=False)
```

Al ejecutar este código, el dataset se cargó en memoria como un **DataFrame**, una estructura de datos tabular similar a una hoja de cálculo.

Posteriormente se analizaron distintos aspectos del dataset.

```
# información del dataframe - Data Profiling (entender el dataframe, ver
estructura, tipos de datos, valores nulos, etc.)
```

Dimensiones del dataset

```
df.shape
```

Esto permitió identificar la cantidad total de registros y variables presentes en el archivo.

Nombres de las columnas

```
df.columns
```

Este paso permitió identificar las variables disponibles en el dataset.

Primeros registros

```
df.head()
```

Esto permitió visualizar ejemplos reales de registros y comprender cómo se organizaban los datos.

Este proceso de exploración inicial se conoce como Data Profiling, y es una etapa fundamental antes de cualquier proceso de modelado o transformación de datos.

```
df.columns
df.head(5) # muestra las primeras 5 filas del dataframe
```

Esto permitió visualizar ejemplos reales de registros y comprender cómo se organizaban los datos.

Este proceso de exploración inicial se conoce como **Data Profiling**, y es una etapa fundamental antes de cualquier proceso de modelado o transformación de datos.

5. Identificación del grano del dataset

Uno de los aspectos más importantes en el diseño de un modelo analítico es definir el **grano del dataset**.

El grano responde a la pregunta:

¿Qué representa una fila del dataset?

En el caso del dataset analizado, cada fila representa la **cantidad de nacimientos registrados para una combinación específica de variables demográficas y sanitarias**.

Estas variables son:

- año
- jurisdicción de residencia
- grupo de edad de la madre
- nivel educativo de la madre
- tipo de parto
- semana de gestación
- intervalo de peso al nacer
- sexo del recién nacido

La **métrica asociada** a esta combinación de variables es: **cantidad de nacimientos registrados**

Definir correctamente el grano del dataset es fundamental porque determina la estructura del modelo dimensional y la forma en que se realizarán los análisis posteriores.

6. Diseño del modelo estrella

Una vez identificado el grano del dataset, se diseñó un **modelo dimensional tipo estrella (Star Schema)** para organizar la información de manera eficiente para análisis.

Este tipo de **modelo** es ampliamente utilizado en sistemas de **Business Intelligence** y **Data Warehousing**, ya que permite realizar consultas analíticas de forma rápida y clara.

En este modelo se identificó una **tabla de hechos central** que almacena la métrica principal del sistema, y varias **tablas de dimensiones** que permiten analizar esa métrica desde diferentes perspectivas.

El modelo estrella está compuesto por:

Tablas de dimensiones

Las dimensiones contienen información descriptiva que proporciona contexto a las métricas analizadas.

Las dimensiones identificadas para este dataset fueron:

- dim_tiempo
- dim_jurisdiccion
- dim_edad_madre
- dim_instruccion
- dim_tipo_parto
- dim_semana_gestacion
- dim_peso
- dim_sexo

Cada dimensión contiene atributos descriptivos que permiten clasificar y analizar los datos desde diferentes perspectivas.

Tabla de hechos

La tabla de hechos almacena las **métricas del sistema** y las claves que vinculan cada registro con las dimensiones correspondientes.

La tabla de hechos definida es:


fact_nacimientos

Esta tabla almacena la cantidad de nacimientos registrados y contiene claves foráneas hacia las dimensiones que describen el contexto de cada registro.

Esta tabla contiene:

- las claves de cada dimensión
- la métrica principal: **cantidad de nacimientos**

El modelo estrella permite evitar la repetición de texto y facilita la realización de consultas analíticas.



Este modelo permite realizar análisis multidimensionales tales como:

- distribución de nacimientos por provincia
- relación entre edad materna y nacimientos
- análisis por tipo de parto
- análisis por características del recién nacido

7. Proceso ETL

Para construir el modelo analítico se desarrolló un proceso **ETL (Extract, Transform, Load)** utilizando Python. El proceso consistió en:

Extract (Extracción) - Se cargó el dataset original desde el archivo CSV utilizando pandas.

Transform (Transformación) - Durante esta etapa se realizaron distintas transformaciones para adaptar el dataset al modelo dimensional:

- separación de variables en tablas de dimensiones
- generación de claves para cada dimensión
- construcción de la tabla de hechos
- preparación de archivos listos para cargar en el Data Warehouse

Load (Carga) - Como resultado del proceso ETL se generaron distintos archivos CSV correspondientes a:

Dimensiones:

- dim_tiempo
- dim_jurisdiccion
- dim_edad_madre
- dim_instruccion
- dim_tipo_parto
- dim_semana_gestacion
- dim_peso
- dim_sexo


Tabla de hechos:

- fact_nacimientos

Estos archivos fueron exportados desde Python y serán utilizados para cargar la información en el Data Warehouse implementado en **SQL Server**.

Arquitectura del pipeline de datos

El flujo completo de procesamiento de datos implementado en este proyecto puede resumirse en el siguiente pipeline analítico:



Este pipeline permite transformar datos crudos provenientes de fuentes públicas en información analítica estructurada que puede ser utilizada para la toma de decisiones.

8. Implementación del Data Warehouse

Creación de la base de datos analítica

El Data Warehouse del proyecto fue implementado utilizando SQL Server Express mediante la herramienta SQL Server Management Studio (SSMS).

Se creó una base de datos dedicada al proyecto denominada:

DW_Salud

Esta base funcionará como repositorio central para almacenar las tablas de dimensiones y la tabla de hechos generadas durante el proceso ETL realizado en Python.

La creación de la base se realizó mediante el siguiente comando SQL:

```
CREATE DATABASE DW_Salud;
```

Recreación del modelo físico

Durante la implementación inicial se detectó una incompatibilidad entre las claves surrogate generadas en Python y la definición de columnas IDENTITY en SQL Server. Para corregir esta situación, se decidió recrear la base DW_Salud desde cero.

Las dimensiones fueron redefinidas sin IDENTITY, permitiendo cargar directamente las claves generadas durante el proceso ETL. Esta decisión aseguró la correspondencia entre dimensiones y tabla de hechos, y permitió mantener la integridad del modelo estrella.

Creación de esquemas y tablas

Luego de crear la base de datos **DW_Salud**, se definieron distintos esquemas para organizar las tablas del Data Warehouse.

Se crearon los siguientes esquemas:

- **dim**: contiene las tablas de dimensiones
- **fact**: contiene la tabla de hechos
- **staging**: reservado para la etapa de carga intermedia de datos

La utilización de esquemas permite organizar mejor las tablas dentro de la base de datos y facilita la administración del modelo analítico.

Posteriormente se crearon las tablas dimensionales y la tabla de hechos siguiendo el modelo estrella diseñado previamente.

Las tablas de dimensiones implementadas fueron:

- dim.dim_tiempo
- dim.dim_jurisdiccion
- dim.dim_edad_madre
- dim.dim_instruccion
- dim.dim_tipo_parto
- dim.dim_semana_gestacion
- dim.dim_peso
- dim.dim_sexo

La tabla de hechos implementada fue:

- fact.fact_nacimientos

Cada tabla de hechos contiene claves foráneas que referencian a las dimensiones correspondientes.

Carga de datos en el Data Warehouse mediante BULK INSERT

Una vez recreadas las tablas del modelo dimensional, se procedió a cargar los datos generados durante el proceso ETL en Python.

Para realizar esta carga se utilizó la sentencia **BULK INSERT** de SQL Server.

BULK INSERT es una instrucción que permite importar grandes volúmenes de datos desde archivos externos (como archivos CSV) directamente hacia tablas de una base de datos.

Esta técnica es ampliamente utilizada en procesos ETL porque permite cargar datos de manera rápida y eficiente sin necesidad de utilizar asistentes gráficos.

En este proyecto, los archivos CSV generados en Python para cada dimensión y para la tabla de hechos fueron cargados en SQL Server mediante sentencias BULK INSERT.

Corrección de codificación de caracteres

Durante la etapa de carga se detectaron inconsistencias en la representación de caracteres acentuados en algunos valores descriptivos, particularmente en nombres de jurisdicciones.

Este problema se originó debido a diferencias en la codificación de caracteres entre el archivo original y la interpretación realizada por las herramientas utilizadas.

Dado que el número de registros afectados era reducido, se optó por realizar una corrección manual de los valores para esta versión del proyecto, con el objetivo de garantizar la correcta visualización de los datos.

En una implementación productiva, este tipo de correcciones debería resolverse dentro del proceso ETL mediante un tratamiento adecuado de la codificación de caracteres.

9. Consultas analíticas

Evolución de nacimientos por año

Una de las primeras consultas realizadas sobre el Data Warehouse fue analizar la evolución de la cantidad total de nacimientos registrados por año.

Para ello se utilizó la tabla de hechos `fact_nacimientos` y la dimensión `dim_tiempo`.

```
SELECT dt.anio, SUM(fn.nacimientos_cantidad) as total_nacimientos
FROM fact.fact_nacimientos fn
JOIN dim.dim_tiempo dt on fn.tiempo_key = dt.tiempo_key
GROUP BY dt.anio
ORDER BY dt.anio ASC;
```

Esta consulta permite observar la evolución temporal de los nacimientos registrados en Argentina entre los años 2005 y 2022.

Distribución de nacimientos por jurisdicción

Para analizar la distribución geográfica de los nacimientos registrados en Argentina, se realizó una consulta que agrupa la cantidad total de nacimientos por jurisdicción de residencia.

Esta consulta utiliza la tabla de hechos `fact_nacimientos` y la dimensión `dim_jurisdiccion`.

```
-- ¿Qué provincias registraron mayor cantidad de nacimientos?

SELECT dj.jurisdiccion_residencia_nombre, SUM(fn.nacimientos_cantidad) as total_nacimientos
FROM fact.fact_nacimientos fn
JOIN dim.dim_jurisdiccion dj on fn.jurisdiccion_key = dj.jurisdiccion_key
GROUP BY dj.jurisdiccion_residencia_nombre
ORDER BY total_nacimientos DESC;
```

Esta consulta permite identificar qué jurisdicciones registran mayor cantidad de nacimientos en el período analizado.

Distribución de nacimientos según edad de la madre

Se realizó una consulta para analizar la distribución de nacimientos según el grupo de edad de la madre, utilizando la dimensión `dim_edad_madre`.

```
--¿Cómo se distribuyen los nacimientos según el grupo de edad de la madre?  
SELECT dem.edad_madre_grupo, SUM(fn.nacimientos_cantidad) as total_nacimientos,  
ROUND(  
SUM(nacimientos_cantidad)*100/SUM(SUM(fn.nacimientos_cantidad)) OVER(),  
2) AS porcentaje  
FROM fact.fact_nacimientos fn  
JOIN dim.dim_edad_madre dem on fn.edad_madre_key = dem.edad_madre_key  
GROUP BY dem.edad_madre_grupo  
ORDER BY total_nacimientos DESC;
```

Esta consulta permite identificar qué grupos etarios concentran mayor cantidad de nacimientos, facilitando el análisis demográfico de la población.

Distribución de nacimientos según edad de la madre y tipo de parto

Se realizó una consulta multidimensional para analizar la relación entre el grupo de edad de la madre y el tipo de parto registrado.

La consulta utiliza la tabla de hechos `fact_nacimientos` junto con las dimensiones `dim_edad_madre` y `dim_tipo_parto`.

```
--¿Cómo se distribuyen los nacimientos según edad de la madre y tipo de parto?  
SELECT dem.edad_madre_grupo, dtp.tipo_de_parto_nombre,  
SUM(fn.nacimientos_cantidad) as total_nacimientos  
FROM fact.fact_nacimientos fn  
JOIN dim.dim_edad_madre dem on fn.edad_madre_key = dem.edad_madre_key  
JOIN dim.dim_tipo_parto dtp on fn.tipo_parto_key = dtp.tipo_parto_key  
GROUP BY dem.edad_madre_grupo, dtp.tipo_de_parto_nombre  
ORDER BY total_nacimientos DESC;
```

Esta consulta permite observar cómo se distribuyen los nacimientos según distintas combinaciones de variables demográficas y sanitarias.

Evolución de nacimientos por año y jurisdicción

Con el objetivo de analizar la evolución temporal y geográfica de los nacimientos registrados en Argentina, se realizó una consulta que combina la dimensión tiempo con la dimensión jurisdicción.

```
--¿Cómo evolucionaron los nacimientos por provincia a lo largo de los años?  
SELECT dt.anio, dj.jurisdiccion_residencia_nombre,  
SUM(fn.nacimientos_cantidad) as total_nacimientos  
FROM fact.fact_nacimientos fn  
JOIN dim.dim_tiempo dt on dt.tiempo_key = fn.tiempo_key  
JOIN dim.dim_jurisdiccion dj on dj.jurisdiccion_key = fn.jurisdiccion_key  
GROUP BY dt.anio, dj.jurisdiccion_residencia_nombre  
ORDER BY dt.anio DESC, total_nacimientos DESC;
```

Esta consulta permite identificar variaciones temporales y diferencias regionales en la cantidad de nacimientos registrados.

Evolución de nacimientos en Buenos Aires entre 2015 y 2020

Con el objetivo de analizar el comportamiento temporal de los nacimientos en la provincia de Buenos Aires, se realizó una consulta filtrando la jurisdicción y el rango de años de interés.

Uso de claves para filtros analíticos

Durante la construcción de las consultas se observó que algunos filtros basados en texto podrían generar resultados ambiguos. Por ejemplo, al buscar valores relacionados con “Buenos Aires”, podían aparecer tanto la provincia de Buenos Aires como la Ciudad Autónoma de Buenos Aires.

Para evitar ambigüedades, se utilizó la clave de jurisdicción correspondiente dentro del modelo dimensional. Esta decisión permite trabajar con identificadores únicos, evitar errores por diferencias de escritura y mejorar la precisión de las consultas.

```
--Cantidad de nacimientos en la provincia de Buenos Aires entre 2015 y 2020
SELECT dt.anio,
SUM(fn.nacimientos_cantidad) as total_nacimientos
FROM fact.fact_nacimientos fn
JOIN dim.dim_tiempo dt on dt.tiempo_key = fn.tiempo_key
WHERE fn.jurisdiccion_key = 2 AND dt.anio BETWEEN 2015 AND 2020
GROUP BY dt.anio
ORDER BY dt.anio ASC;
```

Esta consulta permite analizar la evolución de nacimientos de una jurisdicción específica entre los años 2015 y 2020, utilizando la clave de jurisdicción como filtro principal.

Participación porcentual de nacimientos por jurisdicción

Con el objetivo de analizar la participación relativa de cada jurisdicción sobre el total nacional de nacimientos, se realizó una consulta utilizando funciones ventana (`OVER()`).

```
--¿Qué porcentaje representa cada jurisdicción sobre el total nacional de nacimientos?
SELECT dj.jurisdiccion_residencia_nombre, SUM(fn.nacimientos_cantidad) as total_nacimientos,
CAST(
SUM(fn.nacimientos_cantidad)*100.00
/SUM(SUM(fn.nacimientos_cantidad)) OVER() AS decimal (10,2)
) AS porcentaje
FROM fact.fact_nacimientos fn
JOIN dim.dim_jurisdiccion dj on dj.jurisdiccion_key = fn.jurisdiccion_key
GROUP BY dj.jurisdiccion_residencia_nombre
ORDER BY total_nacimientos DESC;
```

Esta consulta permite identificar qué porcentaje del total nacional representa cada jurisdicción, facilitando el análisis comparativo entre provincias.

10. Visualización en Power BI y análisis de resultados

El presente proyecto culminó con el desarrollo de un dashboard interactivo en Power BI orientado al análisis multidimensional de los nacimientos registrados en la República Argentina durante el período 2005–2022. La visualización fue diseñada con un enfoque analítico y ejecutivo, permitiendo interpretar tendencias temporales, patrones territoriales y relaciones socioeconómicas vinculadas a los nacimientos.

Para la construcción del dashboard se utilizaron medidas DAX, segmentadores dinámicos, gráficos comparativos y KPIs ejecutivos que permitieron transformar los datos procesados en información visual comprensible y útil para la toma de decisiones.

El dashboard se estructuró en cuatro páginas temáticas principales:

10.1 Overview General

La primera página presenta un panorama general de los nacimientos registrados en Argentina. Incluye indicadores clave como:

- Total de nacimientos registrados.
- Grupo etario predominante de las madres.
- Tipo de parto predominante.
- Nivel educativo predominante.

Además, se incorporaron visualizaciones temporales y distribuciones comparativas que permiten identificar:

- Evolución de la natalidad entre 2005 y 2022.
- Concentración de nacimientos según edad materna.
- Distribución de nacimientos por nivel educativo.
- Relación entre edad materna y perfil educativo.

Los resultados obtenidos evidencian una disminución progresiva de la cantidad de nacimientos hacia el período 2018–2022, así como una fuerte concentración de nacimientos en madres de entre 20 y 34 años.

10.2 Perfil Materno y Social

La segunda página se orienta al análisis socioeconómico de la maternidad. Se trabajó especialmente sobre la relación entre:

- Edad materna.
- Nivel educativo alcanzado.
- Maternidad adolescente.
- Distribución territorial.

Para ello se implementaron:

- Tablas tipo heatmap.
- Barras apiladas porcentuales.
- KPIs de maternidad adolescente.

- Rankings provinciales.

El análisis permitió observar que la maternidad adolescente presenta una asociación significativa con niveles educativos incompletos, especialmente en estudios secundarios no finalizados. Asimismo, se identificó que las provincias del norte argentino presentan mayores porcentajes relativos de maternidad adolescente en comparación con otras regiones del país.

10.3 Tipo de Parto y Salud Neonatal

La tercera página incorpora indicadores vinculados a salud materno-infantil y condiciones neonatales, analizando:

- Bajo peso al nacer.
- Prematuridad.
- Semanas de gestación.
- Relación entre edad materna y condiciones de nacimiento.

Se desarrollaron gráficos porcentuales comparativos para identificar diferencias entre grupos etarios y posibles factores de riesgo.

Los resultados muestran que los grupos etarios extremos (madres menores de 15 años y mayores de 45 años) presentan mayores proporciones relativas de nacimientos prematuros y bajo peso al nacer. A su vez, los nacimientos a término continúan representando la mayor proporción dentro de todos los grupos analizados.

10.4 Análisis Territorial y Evolución Temporal

La cuarta página integra análisis territorial y temporal mediante:

- Mapas interactivos.
- KPIs sanitarios.
- Evolución temporal de indicadores.
- Comparación de tendencias nacionales.

Entre los indicadores analizados se incluyeron:

- Porcentaje de maternidad adolescente.
- Bajo peso al nacer.
- Prematuridad.
- Evolución total de nacimientos.

La visualización permitió detectar diferencias regionales importantes y tendencias temporales relevantes, especialmente una disminución sostenida de la natalidad y una reducción significativa de la maternidad adolescente hacia los años posteriores a 2018.

10.5 Conclusiones analíticas generales

El dashboard permitió identificar relaciones relevantes entre variables sanitarias, educativas y territoriales, demostrando el potencial del análisis de datos aplicado a salud pública.

La utilización de herramientas de Business Intelligence facilitó la integración de grandes volúmenes de información y su transformación en conocimiento útil para análisis exploratorios y estratégicos.

Asimismo, el proyecto evidencia cómo un enfoque basado en datos puede contribuir a detectar desigualdades regionales, patrones poblacionales y posibles áreas prioritarias de intervención sanitaria y social.

11. Aplicaciones en gestión pública

La implementación de soluciones de análisis de datos y Business Intelligence en organismos públicos representa una herramienta estratégica para mejorar la planificación, el monitoreo y la toma de decisiones basadas en evidencia.

En este proyecto, el análisis de nacimientos registrados en Argentina permitió observar cómo los datos abiertos gubernamentales pueden transformarse en información útil para comprender fenómenos demográficos, sanitarios y sociales de relevancia nacional.

El desarrollo de un Data Warehouse junto con dashboards interactivos posibilita centralizar información proveniente de múltiples fuentes y generar indicadores comparables a lo largo del tiempo y entre diferentes jurisdicciones.

11.1 Aplicaciones potenciales

Entre las posibles aplicaciones prácticas de este tipo de solución se destacan:

• Monitoreo de indicadores sanitarios

Permite realizar seguimiento de:

- natalidad,
- prematuridad,
- bajo peso al nacer,
- maternidad adolescente,
- distribución territorial de nacimientos.

Esto facilita detectar cambios significativos y tendencias emergentes.

• Planificación de recursos públicos

El análisis territorial puede utilizarse para:

- identificar regiones con mayores necesidades sanitarias,
- planificar infraestructura hospitalaria,
- distribuir recursos humanos,
- orientar campañas de prevención y asistencia.

• Diseño de políticas públicas

La relación observada entre variables educativas, sociales y sanitarias puede contribuir al diseño de políticas orientadas a:

- salud sexual y reproductiva,
- educación,
- prevención del embarazo adolescente,
- fortalecimiento del acceso a controles prenatales.

• Evaluación de impacto temporal

La incorporación de análisis históricos permite evaluar variaciones en indicadores a lo largo de distintos períodos temporales, incluyendo contextos económicos, sanitarios y sociales particulares.

Sin adoptar posiciones partidarias, el análisis evidencia que los cambios estructurales, el acceso a recursos y determinadas políticas públicas pueden influir indirectamente sobre los indicadores analizados.

• Democratización del acceso a la información

La utilización de herramientas visuales facilita que información compleja pueda ser interpretada no solo por especialistas técnicos, sino también por:

- funcionarios,
- equipos interdisciplinarios,
- instituciones educativas,
- investigadores,
- ciudadanía en general.

11.2 Importancia del análisis de datos en el sector público

El crecimiento de las tecnologías de datos y Business Intelligence representa una oportunidad para modernizar procesos de gestión estatal y mejorar la eficiencia administrativa.

La integración entre bases de datos, análisis estadístico y visualización interactiva permite transformar grandes volúmenes de datos en información estratégica para la toma de decisiones.

En este sentido, proyectos como el desarrollado demuestran el valor del análisis de datos aplicado a problemáticas reales, aportando herramientas que pueden contribuir a una gestión pública más eficiente, transparente y orientada a evidencia objetiva.

12. Conclusiones finales

12.1 Conclusión general del proyecto

El presente proyecto permitió desarrollar una solución integral de análisis de datos aplicada al estudio de los nacimientos registrados en la República Argentina durante el período 2005–2022.

A través de la construcción de un proceso ETL, el diseño de un modelo dimensional y la implementación de dashboards interactivos en Power BI, fue posible transformar datos abiertos gubernamentales en información visual y analítica útil para la interpretación de fenómenos demográficos, sociales y sanitarios.

El análisis realizado permitió identificar tendencias relevantes, entre ellas:

- una disminución sostenida de la natalidad hacia los últimos años del período analizado,
- una reducción progresiva de la maternidad adolescente,
- diferencias territoriales significativas entre provincias,
- y relaciones entre variables educativas, etarias y sanitarias.

Asimismo, se observaron patrones que sugieren vínculos entre condiciones socioeconómicas, acceso educativo y determinados indicadores de salud materno-infantil, especialmente en grupos etarios extremos y regiones con mayores niveles de vulnerabilidad social.

12.2 Reflexión sobre el uso de datos en salud pública

El desarrollo del proyecto permitió comprender la importancia del análisis de datos como herramienta para la toma de decisiones basadas en evidencia dentro del ámbito público y sanitario.

La posibilidad de integrar, modelar y visualizar información histórica facilita:

- detectar tendencias,
- monitorear indicadores críticos,
- identificar desigualdades regionales,
- y orientar políticas públicas de forma más eficiente.

Sin adoptar enfoques partidarios ni realizar interpretaciones políticas directas, el análisis evidencia que los contextos sociales, económicos y sanitarios pueden influir sobre los indicadores estudiados, resaltando la importancia de sostener estrategias de prevención, educación y acceso a servicios de salud de manera continua.

12.3 Aprendizajes técnicos obtenidos

Desde el punto de vista técnico, el proyecto permitió aplicar conocimientos relacionados con:

- procesos ETL mediante Python,
- limpieza y transformación de datos,
- modelado dimensional,
- diseño de Data Warehouses,
- consultas SQL,
- creación de métricas DAX,
- visualización de datos en Power BI,
- y desarrollo de dashboards interactivos.

Además, se fortaleció la comprensión sobre la importancia de la calidad de datos, la consistencia de las dimensiones y la correcta estructuración de modelos analíticos para obtener resultados confiables.

12.4 Proyección futura del proyecto

Como líneas futuras de desarrollo, el proyecto podría ampliarse incorporando:

- nuevos datasets sanitarios,
- indicadores económicos y sociales complementarios,
- tasas de mortalidad infantil,

- acceso a cobertura médica,
- infraestructura hospitalaria,
- y análisis predictivos mediante técnicas de Machine Learning.

Asimismo, el modelo desarrollado podría adaptarse para su utilización en organismos públicos, municipios o instituciones de salud interesadas en implementar soluciones de Business Intelligence orientadas al análisis territorial y sanitario.

